SWEET.TV: прогноз любимых телепрограмм

Студент: **Евдокимов Николай Николаевич** · Individual
Email: nevdokimov@hse.ru · Kaggle: nickevdokimov · Midterm Quiz / ФКН

Аннотация. Требуется предсказать пять будущих предпочитаемых программ по неполным логам телеканалов. История соединена с расписанием по каналу и пересечению интервалов; на одном временном hold-out сравнены популярность, CBF, Association Rules и частотные стратегии. Выбранный гибрид получил MAP@5=0.37886 против 0.26970 у популярности, Kaggle private score=0.40716. Повторные предпочтения дают сильный ориентир, а небольшой выигрыш гибрида над личной частотой требует осторожной интерпретации.

1. Постановка и источники требований

Вход: история недель 11–30 и расписание до недели 42; выход: пять упорядоченных ID для каждого из 1260 пользователей. Экзамен [1, 2] требует два допустимых метода сверх popularity и общий протокол. Официальная страница [3] сообщает: цель составлена из пяти наиболее частых программ с долей просмотра ≥80%; public/private разделены по пользователям 50/50. Место замороженного leaderboard не используется для оценки. Дедлайн: 01.11.2026, 19:00 МСК.

2. Фактические данные и сопоставление

CSV	Строк	Уникальные ID / пользователи
dataset11-30	5 821 987	4 914 пользователей; 202 канала
Расписание 11–20	1 074 235	5 847 положительных ID; 400 каналов
Расписание 21–30	1 074 394	6 363 положительных ID; 403 каналов
Расписание 31–42	1 295 378	6 636 положительных ID; 404 каналов
submission	1 260	user_id,tv_show_id; 5 ID через пробел

Исходные CSV имеют запятую как разделитель и UTF-8. user_id читается строкой: многие ID превышают знаковый int64 и точность float. Нулевые tv_show_id исключены как неразмеченный эфир: в первом расписании 115613/1074235 = 10,76% строк имеют положительный ID. В дополнительных материалах число «уникальных программ» на единицу больше фактического числа положительных ID: там включён 0.

Фактические логи: 09.03.2020 00:00:02 – 26.07.2020 23:59:58. Формат логов YYYY-MM-DD, расписания DD.MM.YYYY. Часовые пояса в файлах отсутствуют; принято одинаковое локальное wall-clock время без сдвига, абсолютная зона не подтверждена. Удалено 17 дублей логов и один эфир нулевой длительности. Пустых ключей/времён в логах нет; 117 значений duraton расходятся с временами, поэтому используется stop−start. Медиана просмотра 396 s, максимум 342145 s.

Равенство vsetv_id и channel_id явно подтверждено [3] и проверено по множествам: 5708392/5821970 логов имеют известный канал; отсутствуют каналы 1174, 1510, 1509, 1508, 149 (113578 логов). Расписания немного выходят за номинальные недели: разделение сделано по timestamp. Пропуски жанров и персоналий допустимы: отсутствующие признаки не заменяются выдуманными значениями.

3. Взаимодействия и отсутствие утечек

Для просмотра [s,e) и эфира [a,b) на одном канале пересечение равно max(0,min(e,b)−max(s,a)). Day-bucketing ограничивает соединение, затем применяется точная проверка интервалов. Один лог может пересечь несколько эфиров; фрагменты каждого user–airing объединяются в непересекающиеся интервалы. Просмотр засчитывается при union_seconds / duration ≥0,8. Каждый повторный эфир даёт отдельное событие, затем события одного user–ID суммируются.

Покрытие: с любым эфиром пересеклись 5 408 582 логов, с положительным ID — 2 964 335 (50.9%); получено 3 014 129 пар user–airing, 611 760 покрытий ≥80% до граничных фильтров. Без такой истории остались 73 из 4914 пользователей; в финальном шаблоне — 4 из 1260. У 590192 логов несколько размеченных эфиров. Найдено 13 строк расписания с перекрытием предыдущего эфира канала: сохранены заданные эфиры, возможна неоднозначность.

Абсолютный порог 300 s допускает 2078912 user–airing пар, включая малую долю длинной программы. Порог 80% выбран по официальному правилу, а 300 s проверен только как альтернатива для обучения при неизменной цели. Отсутствующие или невалидные времена не восстанавливаются. ID=0 используется лишь в аудите покрытия, не в моделях.

4. Единый временной протокол и MAP@5

Обучение [09.03,18.05), hold-out [18.05,27.07), 2020 год. Эфиры, пересекающие границу, не создают метки; исключено 2156 таких user–airing пар. Обучающих событий 316 314, user–ID пар 114 754. Модели обучаются на всей доступной прошлой истории 4914 пользователей; оценка — на фиксированном списке шаблона. Цель: до пяти уникальных ID по частоте квалифицированных просмотров после границы, равенства разрешаются меньшим ID.

Общие кандидаты: 6384 положительных ID эфиров, пересекающих hold-out; покрытие релевантных ID 100%. Из 1260 пользователей у 1238 непустая цель, у 1150 — пять ID; 22 пустые цели исключены из основной MAP и отдельно получают 0. Без обучающей истории — 18 пользователей, из них 14 с целью. Повторные ID разрешены: 60.6% целей уже встречались в обучении. Рекомендации уникальны внутри списка. Метаданные, словарь и IDF — строго до границы; будущее расписание даёт только ID/канал/время, не жанры или названия для scoring.

AP@5(u) = [Σ по r=1…5 Precision@r · 1{ID на ранге r релевантен и ещё не засчитан}] / min(5, $|R_u|$). **MAP@5** — среднее AP по пользователям выбранной группы. Порядок предсказаний влияет на precision; порядок целевого набора не взвешивается. Формула соответствует слайду 4 [1], примеры слайда 5 проверены кодом (11/12 и 8/15). Kaggle не публикует полный код цели; слияние фрагментов и tie-break локально зафиксированы, их тождество скрытой разметке не заявляется.

5. Реализованные модели

Popularity: число уникальных обучающих зрителей ID. **Repeat:** число квалифицированных эфиров пользователя; вариант 28 использует вес каждого события 2^(−age_days/28). **CBF:** DictVectorizer + TF-IDF [4], L2-нормировка item-векторов и суммы векторов просмотренного. Score — cosine. Признаки: категория/название (вес 1), жанры/режиссёр (2), актёры (1,5), год (0,5); пропуски игнорируются, значения поля выбираются модой прошлого расписания. ID не является признаком.

Association Rules: корзина — уникальная история пользователя. Правило i→j имеет вес n(i,j)/(n(i)+λ); минимум 3 общих зрителя, максимум 100 следствий, i→i удалено. Score — сумма правил с весом √частоты antecedent; λ=5 или 20. Разреженные матрицы SciPy [5]. Для всех методов положительные score ранжируются первыми, затем общий fallback Popularity; ties — popularity и ID. У пользователя без истории все методы возвращают один и тот же Top-5 popularity. Модели могут переоценивать популярные передачи и не различают домочадцев.

6. Сравнение и выбор стратегии

Среда: Python 3.12.14, macOS 26.5.1 / arm64, 11 логических CPU; DuckDB 2.0.0, NumPy 2.5.4, SciPy 1.18.1, scikit-learn 1.9.1. DuckDB: 4 потока, memory_limit=3 GB. Подготовка: 20.39 s, peak RSS 2.33 GiB. Полный цикл моделей: 8.15 s; финальное обучение и ранжирование: 1.21 s. Seed 42 для bootstrap; сами модели детерминированы. Время ниже включает построение score и Top-5, но не I/O подготовки.

Метод / конфигурация	MAP@5	Все 1260	|R|=5	Время, s
Popularity	0.26970	0.26499	0.27710	0.167
Repeat	0.37402	0.36749	0.38839	0.178
Repeat-28	0.35841	0.35215	0.37247	0.203
CBF	0.29228	0.28717	0.30094	0.555
CBF-28	0.29400	0.28887	0.30314	0.602
AR λ=5	0.26810	0.26342	0.27611	0.261
AR λ=20	0.26708	0.26241	0.27471	0.262
AR λ=20, 28d	0.26694	0.26228	0.27476	0.284
H 80/20/0, 28d	0.37219	0.36569	0.38644	0.691
H 90/10/0, 28d	0.36921	0.36276	0.38359	0.691
H 80/10/10, 28d	0.37342	0.36690	0.38786	1.511
H 60/20/20, 28d	0.37469	0.36815	0.38856	1.517
H 80/10/10, Repeat без decay	0.37782	0.37122	0.39231	1.495
H 60/20/20, Repeat без decay	0.37886	0.37225	0.39247	1.478
Repeat-28, порог 300 s (диагн.)	0.34559	0.33956	0.35975	0.357

H: веса Repeat / AR-20-28 / CBF-28. Перед сложением каждый score делится на максимум этого пользователя среди кандидатов (нулевой максимум → нулевой вектор). Рейтинги не являются вероятностями. Первоначально проверены 12 конфигураций; после ухудшения Repeat-28 добавлены два гибрида с отключением decay только у Repeat. Порог 300 s — отдельная диагностика, не кандидат выбора. Полная сетка и отрицательные результаты сохранены в artifacts/experiments.json.

Выбрано: H 60/20/20 с Repeat без decay, MAP=0.37886, прирост к popularity 0.10916. Парный percentile bootstrap (2000 выборок пользователей): [0.09819; 0.12061]. К Repeat прирост 0.00484, интервал [-0.00017; 0.00986], включая 0. Интервалы описательные: та же выборка использована для настройки, поправки на выбор модели нет. Надёжное превосходство над Repeat не установлено.

7. Проверки и реальный исправленный дефект

7 unit tests проверяют AP, пустые цели, дубли предсказаний, fallback, касание интервалов, вложенные/одинаковые интервалы, направленность AR и нулевую диагональ. Независимая Python-проверка 200 user–airing пар совпала с SQL. Тест загрузчика исключил будущие метаданные. Два обучения с нуля дали одинаковые SHA-256 всех предсказаний и submission.

Аудит обнаружил долю 2,0 у user 1388513685702887520, эфир 22.05.2020 07:45–07:50. Два лога обрезались до одинаковых границ; оконные функции с ORDER BY s,e могли по-разному упорядочить равенства и создать два острова. Добавлен общий tie-break log_id; доля стала 1,0, добавлены regression test и assert fraction≤1 для всей базы. Это проверка агента, а не заявление о личном выполнении студентом.

Личная интерпретация студента

«Для этой посылки я оставляю гибрид из-за чуть более высокого MAP@5 , но интервал разницы включает ноль, поэтому убедительного преимущества над Repeat пока нет. Пример с детской историей показывает возможный недостаток гибрида: добавленные новости снизили AP с 0,76 до 0,55, хотя одного случая недостаточно для общего вывода. На реальной платформе я бы не заменял Repeat без дополнительной проверки. Следующим экспериментом я бы уменьшил вес новизны для пользователей с однородной историей и сравнил этот вариант с обоими исходными методами на отложенных данных, отдельно оценив MAP@5 и доверительный интервал разницы для пользователей с преимущественно детскими просмотрами».

Уточнение реализации: отдельного веса новизны нет; предложение можно задать снижением доли AR/CBF для однородной истории. Это следующий эксперимент, он не проводился.

8. Истории и одинаковые примеры для всех методов

Выбор детерминирован: самая насыщенная обучающая история среди оцениваемых пользователей и самая короткая непустая история (ties по user_id). Примеры не выбраны по удачным рекомендациям. Названия/категории ниже из расписания до конца hold-out нужны только для объяснения, не для обучения.

A: 10500740270951698446 — 904 эфира, 97 ID. Главные ID: 12001682 «Губка Боб» (401), 12002856 «Элвиннн» (68), 2400480 «ТСН» (62). Цель: 12001682 (198), 12002856 (55), 12001697 (43), 2400480 (36), 12002355 (36).
B: 12453026253397466416 — 1 эфир, ID 200337 «Утро с Интером». Цель: 240081 (9), 2400480 (3), 5200303 (3), 20088 (2), 200337 (1). Числа в скобках — частоты квалифицированных эфиров в соответствующем периоде.

A · Popularity · AP=0.200			**B · AP=0.400**		
1. 2400480+	ТСН.	Инфо	1. 2400480+	ТСН.	Инфо
2. 240081	Факты.	Инфо	2. 240081+	Факты.	Инфо
3. 2400467	'Викна-Новости'.	Инфо	3. 2400467	'Викна-Новости'.	Инфо
4. 200344	'Чистonews'.	Развлечения	4. 200344	'Чистonews'.	Развлечения
5. 2400508	Сегодня.	Инфо	5. 2400508	Сегодня.	Инфо

A · CBF-28 · AP=0.760			**B · AP=0.200**		
1. 12001682+	М/с 'Губка Боб Квадратные Штаны'.	Детям	1. 200337+	Утро с Интером.	Развлечения
2. 12002856+	М/с 'Элвиннн!!! и бурундуки'.	Детям	2. 5900275	'Утро России'.	Инфо
3. 2400480+	ТСН.	Инфо	3. 5900256	Утро с Украиной.	Инфо
4. 240081	Факты.	Инфо	4. 200477	'Завтрак. Выходной'.	Развлечения
5. 12001697+	М/с 'Аватар: Легенда об Аанге'.	Детям	5. 2400508	Сегодня.	Инфо

A · AR-20-28 · AP=0.200			**B · AP=0.520**		
1. 2400480+	ТСН.	Инфо	1. 2400480+	ТСН.	Инфо
2. 240081	Факты.	Инфо	2. 240081+	Факты.	Инфо
3. 2400467	'Викна-Новости'.	Инфо	3. 2400508	Сегодня.	Инфо
4. 2400508	Сегодня.	Инфо	4. 2400467	'Викна-Новости'.	Инфо
5. 200344	'Чистonews'.	Развлечения	5. 20088+	'Завтрак с 1+1'. Информационно-развлекательная программа.	Развлечения

A · Repeat · AP=0.760			**B · AP=0.600**		
1. 12001682+	М/с 'Губка Боб Квадратные Штаны'.	Детям	1. 200337+	Утро с Интером.	Развлечения
2. 12002856+	М/с 'Элвиннн!!! и бурундуки'.	Детям	2. 2400480+	ТСН.	Инфо
3. 2400480+	ТСН.	Инфо	3. 240081+	Факты.	Инфо
4. 12001734	М/с 'Волшебные покровители'.	Детям	4. 2400467	'Викна-Новости'.	Инфо
5. 12001697+	М/с 'Аватар: Легенда об Аанге'.	Детям	5. 200344	'Чистonews'.	Развлечения

A · Итоговый H 60/20/20 · AP=0.550			**B · AP=0.453**		
1. 12001682+	М/с 'Губка Боб Квадратные Штаны'.	Детям	1. 200337+	Утро с Интером.	Развлечения
2. 2400480+	ТСН.	Инфо	2. 2400508	Сегодня.	Инфо
3. 240081	Факты.	Инфо	3. 20088+	'Завтрак с 1+1'. Информационно-развлекательная программа.	Развлечения
4. 12002856+	М/с 'Элвиннн!!! и бурундуки'.	Детям	4. 2400467	'Викна-Новости'.	Инфо
5. 2400467	'Викна-Новости'.	Инфо	5. 2400480+	ТСН.	Инфо

«+» — ID входит в Top-5 ground truth; отсутствие знака не доказывает отсутствие просмотра или интереса. Полные истории Top-10 и списки всех конфигураций сохранены в artifacts/user_examples.json.

9. Стратегия платформы и ограничения

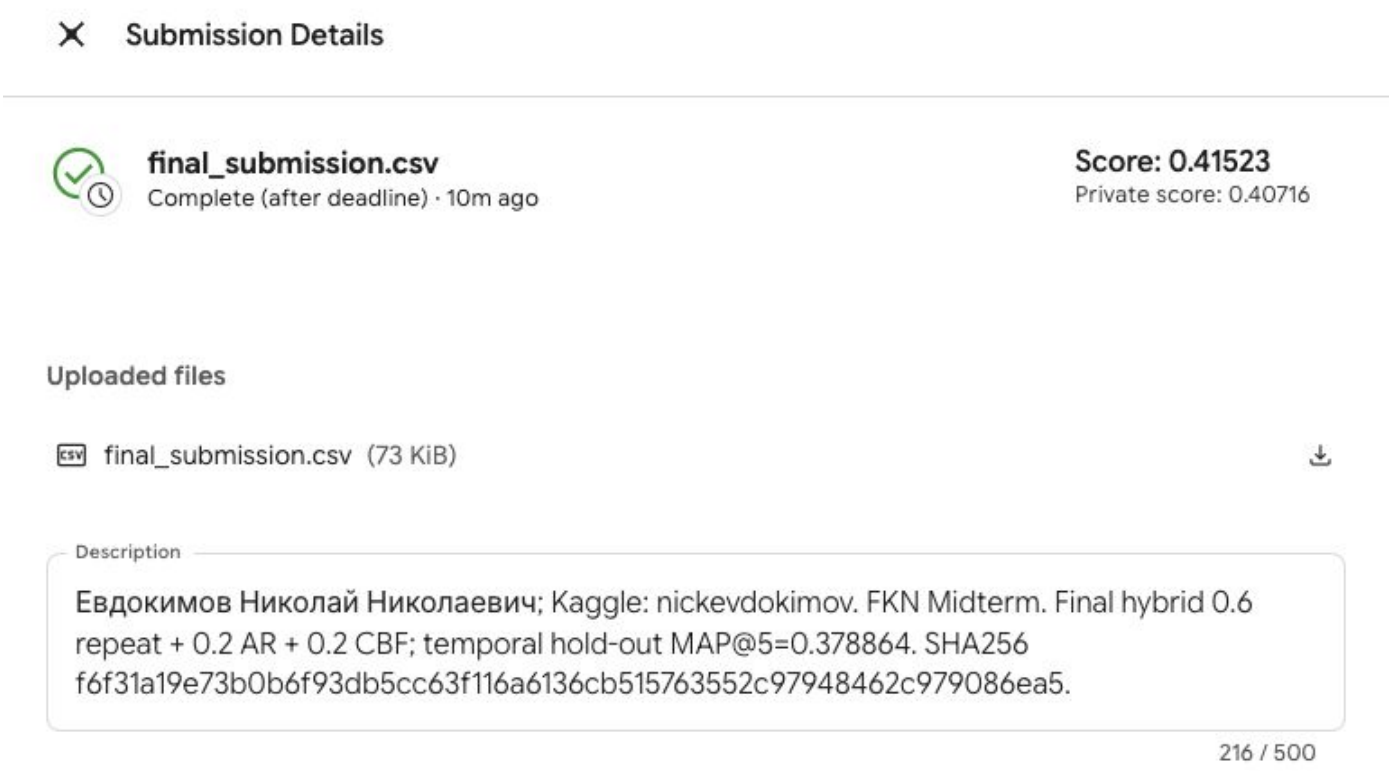
Для этого офлайн-прогноза выбрана смесь с опорой на личную частоту. У A CBF сохраняет детский контент, AR тяготеет к совместно популярным новостям; гибрид вводит «Факты» и «Викна», не попавшие в цель, и получает AP=0,55. У B единственное утреннее шоу мало определяет будущий интерес; AR добавляет «Завтрак с 1+1», а CBF переносит сходство на другие утренние передачи. Гибрид имеет AP=0,453. В обоих примерах Repeat лучше выбранного гибрида: средний выигрыш не гарантирует улучшения каждому зрителю.

Механизм AR основан на совместных зрителях, CBF — на общих атрибутах; первые усиливают массовые новости, вторые могут путать похожий контент с релевантностью. Вычислительные затраты гибрида малы на этой выборке, но преимущества над Repeat неустойчивы. Для реального сервиса полезно сначала проверить простой Repeat и ограничение доли новостей на новом временном срезе. MF и PPR рассматривались как альтернативы, но не реализованы и эмпирически не отвергаются: выбрана интерпретируемая пара без дополнительных латентных/итерационных настроек.

Неразмеченный эфир, 22 пустые цели, неполные атрибуты и 2391 кандидатов hold-out без прошлых метаданных ограничивают переносимость. Один hold-out 10 недель отличается от будущих 12; оценка на пользователях финального шаблона отражает выбранную аудиторию. Незнакомая программа не равна полезному открытию; отсутствие в логах не означает «никогда не смотрел». A/B-тесты и выручка не измерялись.

10. Итоговая посылка и проверка идентичности

Private 0.40716; public 0.41523; Complete. Отправлено пользователем 2026-10-29 21:51:46 МСК. Модель выбрана до score; после отправки не менялась. Скачанный из карточки Kaggle CSV побитово совпал с локальным файлом. Использована одна попытка; форма показывала 100 до / 99 после. Выбор для frozen leaderboard недоступен и не нужен для экзамена.



CSV: artifacts/final_submission.csv · 1260 строк + заголовок, 2 столбца, 5 уникальных положительных ID; все ID есть и в исходном тестовом расписании. SHA-256: f6f31a19e73b0b6f93db5cc63f116a6136cb515763552c97948462c979086ea5

11. AI usage disclosure и личная проверка

Codex Desktop, GPT-6.1 Sol (gpt-6.1-sol), runtime 0.163.0-alpha.10.2: поиск, Python/SQL, отладка, запуски, проверки и текст/PDF; версия подтверждена нативным журналом. Внешние данные, модели и чужой рекомендательный код не использовались. Проверки агента перечислены в §7 и не приписываются студенту.

Личная проверка студента: R={10,20,30}, список [10,99,20,88,30]; precision 1, 2/3, 3/5; AP≈0,7556=34/45. Его обоснование: один ID может объединять разные выпуски, поэтому исключение после первого просмотра скроет новые выпуски. Его личная интерпретация приведена в §7. Личный перезапуск pipeline не заявляется; остальной текст подготовлен AI и требует окончательного прочтения студентом.

Репозиторий: github.com/dryjins/RecSys-LLMs, MidTerm; по просьбе студента публикация отложена. **AI-export:** оригинальный tool-native журнал после завершения работы; JSONL не преобразуется в JSON. Если канал ограничивает расширение, нужно уточнение преподавателя. До публикации, личной правки и окончательного экспорта комплект не готов к сдаче.

Источники

[1] S. Jin. LLM4Rec. Midterm Quiz. Предоставленный PPTX, слайды 2–9, включая изображения с формулой и примерами MAP. Прочитан 29.10.2026.

[2] Final Exam Quiz (FKN): TV Program Recommendation on sweet.tv. Предоставленный exam_quiz_FKN.md, §§2–10. Прочитан 29.10.2026.

[3] ogurbych. sweet.tv — TV program recommender. Kaggle, 2020. Data, Evaluation, Rules и Submission Details проверены в авторизованном браузере 29.10.2026. kaggle.com/competitions/sweettv-tv-program-recommender/data.

[4] scikit-learn developers. Feature extraction; DictVectorizer, TF-IDF. Официальная документация. Прочитана 29.10.2026. scikit-learn.org/stable/modules/feature_extraction.html.

[5] SciPy developers. Sparse arrays (scipy.sparse). Официальная документация. Прочитана 29.10.2026. docs.scipy.org/doc/scipy/reference/sparse.html.

[6] DuckDB Foundation. CSV Import, DuckDB 2.0. Проверены all_varchar, strict_mode и параметры CSV. Прочитано 29.10.2026. duckdb.org/docs/2.0/data/csv/overview.

[7] S. Jin. LLM4Rec — Homework Guidelines. Локальный ../homework_guidelines.pdf, §§2, 4–5, 7–10, FAQ. Проверены требования Gate 0, личной проверки и неизменённого журнала. Прочитан 29.10.2026.