SWEET.TV: время, предпочтения и Top-5

Евдокимов Николай Николаевич · nevdokimov@hse.ru · nickevdokimov
Индивидуальный экзамен LLM4Rec / ФКН · 01.11.2026, 19:00 МСК

Результат. Реализованы popularity, Content-Based Filtering (CBF), Association Rules (AR), implicit ALS и гибриды. Выбран вложенно обученный ранжировщик: средний MAP@5 по трём временным срезам 0.42021; у отправленной v4 HGB — 0,41582. **Черновик: кандидат v6 ещё не имеет подтверждённого Kaggle score.**

1. Данные и интервальные взаимодействия

Файл	Фактические строки	Назначение
dataset11-30	5 821 987	4914 пользователя, 202 канала
export 11–20	1 074 235	5847 положительных ID
export 21–30	1 074 394	6363 положительных ID
export 31–42	1 295 378	6636 положительных ID
submission	1260	user_id,tv_show_id; 5 ID через пробел

Логи: 09.03–26.07.2020; даты логов YYYY-MM-DD, расписаний DD.MM.YYYY. Разделитель CSV — запятая, UTF-8; user_id хранится строкой из-за размера чисел. Часовой пояс не указан: сохранена общая наивная шкала без сдвига. Удалены 17 дублей логов и один нулевой эфир. 117 duraton расходятся со stop−start; используется интервал timestamp. Медиана 396 s, максимум 342145 s.

vsetv_id=channel_id подтверждено Data [3] и проверено по множествам: 5708392/5821970 логов на известном канале. Соединение: одинаковый канал и непустое пересечение [s,e)∩[a,b); секунды=max(0,min(e,b)−max(s,a)). Фрагменты user–airing объединяются в union; ≥80% duration означает квалифицированный просмотр. Повторные эфиры — отдельные события; затем суммируются по user–ID. Один лог может покрыть несколько эфиров.

С положительным ID пересеклись 2964335 логов (50,9%); сформированы 3014129 user–airing пар, 611760 покрытий ≥80% до граничных фильтров. У 73 из 4914 нет такой истории; в финальном шаблоне — 4. Только 10,76% строк первого расписания размечены. ID=0 — не объект; его эфир используется лишь как прошлый контекст канала/времени. Порог 300 s проверен как диагностическая альтернатива: он допускает 2078912 пар, но не соответствует официальному правилу 80%.

2. Временная оценка и MAP@5

Обучение всегда начинается 09.03.2020. Границы / конец прогноза: 20.04 / 29.06; 18.05 / 27.07; 15.06 / 27.07. Те же 1260 пользователей шаблона; оцениваются 1223/1238/1233 с непустой целью. Цель — пять ID по частоте будущих квалифицированных событий, ties по ID. Кандидаты — положительные ID из расписания соответствующего будущего окна; повторные ID разрешены. Общий legal pool, fallback popularity и tie-break одинаковы. Граничные эфиры не входят в labels.

AP@5(u) = sum(i=1..5) Precision@i * hit(i) / min(5,|R|); MAP — среднее AP. Дубликаты предсказаний не дают повторных попаданий. Основная оценка исключает пустой R; дополнительная считает их AP=0. На основном срезе 22 пустые цели, 1150 целей длины 5; все релевантные ID входят в legal pool. Код цели Kaggle не опубликован: точное совпадение правил фрагментов/ties не заявляется.

3. Базовые и дополнительные методы

Popularity: число уникальных прошлых зрителей программы. **Repeat:** персональная частота. **CBF:** DictVectorizer + TF-IDF по прошлым title/category/genre/director/actors/year, L2 item/user cosine; веса title/category 1, genre/director 2, actors 1,5, year 0,5; профиль с 28d decay. **AR:** confidence n(i,j)/(n(i)+20), support≥3, top-100 соседей, sqrt(decayed count), без диагонали. **ALS [4]:** 48 факторов, confidence=1+20·log(1+n), λ=5, 12 точных alternating solves, seed 42; наблюдения implicit, включая confidence=1 у отсутствующих взаимодействий.

v2: личный channel×тип дня×4h профиль из прошлых сырых логов, 21 день сглаживания. Будущие эфиры интегрируются по часовым пересечениям; program lift=(n+1)/(expected_past+1)·expected_future. Score нормируется максимумом пользователя и смешивается с item cosine (binary co-view cosine, support/(support+10), top-80). Вес cosine 0,05 при доле прошлой доминирующей категории ≥0,8 и ≥50 событиях, иначе 0,2. В качестве самостоятельных компонентов они также оценены.

Тренд и мягкое время: Gaussian sigma=3h на циклических часах; дни недели проверены отдельно. 28d half-life применяется согласованно к прошлым просмотрам, часовой экспозиции и эфирам. Это недавняя история и недельные привычки; годовая сезонность по марту–июлю не оценивается. Само сглаживание почти не помогло; чистый недавний профиль дал 0,40965 в среднем.

Итоговый LambdaRank [9,10]: кандидатный гибрид + LightGBM LGBMRanker. 86 признаков: прежние 45 (оценки/ранги методов, история, давность, эфиры и 6 category×time) + 11 признаков привычек и тренда, 7 индикаторов категории, 20 жанров, 3 длительности/разнообразия каналов будущих эфиров. Словарь категорий/жанров зафиксирован по metadata до 23.03; новые ID без прошлой категории остаются неизвестными. Будущие содержательные metadata не читаются. Сырые user/item ID не используются как признаки. Генератор Top-k: v2=40, время=100, Repeat=40, cosine=50, CBF/AR=30, popularity=20.

Группа ранжирования — user×внутреннее окно; бинарная цель — принадлежность будущему Top-5. 100 деревьев, 15 листьев, learning rate 0,07, min child 100, L2=10, truncation=8, label_gain=[0,1], seed=42, 4 потока, deterministic/force_col_wise. LambdaRank оптимизирует NDCG-суррогат; выбор сделан по фактическому MAP@5. Каждый fit использует внутренние окна: минимум 14 дней истории, шаг 14 дней, горизонт до 56 дней, конец labels≤внешняя граница. Внешние labels не используются для fit/early stopping.

Мягкое category×time: sigma=3h, prior=5 событий, half-life=28d. Привычки: число активных дней/недель, доля последних 14 дней, частота с поправкой на эфиры, прошлый персональный и общий тренд. Неотобранным кандидатам score=0, пустой истории — popularity. Ровно 5 уникальных положительных ID; общий tie-break popularity→ID.

Метод	MAP@5 на 18.05–27.07	Время, s
popularity	0.26970	0.168
repeat	0.37402	0.171
cbf28	0.29400	0.588
ar20_28	0.26694	0.291
als48	0.17161	3.157
item_cosine	0.18736	0.311
time_context	0.38838	6.951
program_lift	0.40790	6.941
advanced_hybrid	0.40923	7.324
v4 HGB	0.41903	см. JSON
v5 LambdaRank150	0.42362	см. JSON
LambdaRank100	0.42461	см. §5

4. Выбор по исторической валидации

Стратегия	20.04	18.05	15.06	Среднее
v1	0.40364	0.37886	0.35342	0.37864
v2	0.43830	0.40923	0.37115	0.40622
Недавняя история	0.44035	0.41220	0.37640	0.40965
v4 HGB	0.44312	0.41903	0.38532	0.41582
v5 Rank150	0.44618	0.42362	0.39056	0.42012
v6 Rank100	0.44624	0.42461	0.38977	0.42021

Полная сводка содержит 182 строки, включая повторные references и superseded KNN; это не 182 независимые гипотез. Отрицательные результаты сохранены. Срезы перекрываются и многократно использованы для выбора. Прирост исторический, без независимой временной проверки; bootstrap после широкого поиска не доказывает значимость.

Не помогли: 300×31 HGB (0,41265), partial-view признаки (0,41483), Poisson по будущей частоте во внутренних окнах (0,41119). 1000 дополнительных пользователей из тех же логов дали HGB 0,41598. Признаки привычек отдельно с HGB — 0,41719, item metadata — 0,41619. LambdaRank на 45 признаках — 0,41649; на 86 — 0,42012. 31 лист и rank_xendcg уступили (0,41591 / 0,41780).

Резервная проверка v5 (150 деревьев): после фиксации её параметров выбраны 500 других пользователей, ранее исключённых из расширения обучающей аудитории; 477 имеют непустую цель. Предсказания сохранены до чтения их labels. MAP v5 ranker 0,39649, v4 HGB 0,39670; Δ=−0,00021, paired bootstrap 95% [−0,00567; 0,00538]. Преимущество v5 на этой группе не подтверждено. Календарь/программы общие, это не новый временной период; параметры после проверки не менялись. Для v6 резерв не переиспользован; независимая проверка этой версии отсутствует.

После v5: 6 ансамблей рангов не помогли; 100 деревьев дали 0,420207 против 0,420119 у 150 (Δ=0,000088), но поздний срез ухудшился. 7 листьев, 200 деревьев, top5-truncation и binary-цель уступили. Смеси checkpoints тоже не лучше. Выбор 100 деревьев следует прежнему критерию среднего; это крошечная разница после широкого поиска, без доказанной значимости.

5. Проверки, среда и исправления

Python 3.12.14, macOS 26.5.1 arm64, 11 logical CPU; DuckDB 2.0.0 (4 потока), NumPy 2.5.4, SciPy 1.18.1, sklearn 1.9.1, LightGBM 4.7.0. Подготовка 20.39 s, peak RSS 2.33 GiB. Полный fit+predict финального reranker: 18.78 s; повтор с cache: 17.97 s. Кэш только ускоряет воспроизведение; его ключ включает код и параметры. Сам ranker.fit: 11,16 s; 1454377 обучающих строк, 10783 user×window групп, сумма размеров групп проверена.

18 unit tests: AP, fallback, интервалы и union, направленность AR, ALS objective/determinism/cold start, будущие логи, midnight wrap и вложенные границы. Независимый Python union для 200 пар совпал с SQL. Финальный hold-out переобучен: все 1260 списков идентичны. Два полных fit дали одинаковый CSV SHA-256; предыдущие CSV сохранены.

Исправлены реальные дефекты: равные clipped intervals давали fraction=2,0 из-за разных SQL tie-break (добавлен log_id, assert fraction≤1); исследовательский KNN использовал число всех roster rows для IDF (заменено числом активных прошлых пользователей; старые KNN числа superseded). v2 не использует этот KNN; после ограничения roster прошлым все её списки на трёх срезах совпали. Integer popularity нельзя было делить с integer output: нормирование переведено в float, добавлен тест.

6. Честность и личная проверка

Codex Desktop / gpt-6.1-sol, runtime 0.163.0-alpha.10.2: код, отладка, вычисления и PDF подготовлены с AI. Нативная сессия сохраняется неизменённой; AI-проверки не приписываются студенту. Студент лично вычислил AP=(1+2/3+3/5)/3=34/45≈0,7556 и объяснил повторы выпусков. Он предложил проверить мягкое «утро/вечер» и тренд последних недель; оба проверены, отрицательные результаты сохранены. Личный запуск всего pipeline студентом не заявляется.

7. Истории и рекомендации

A=10500740270951698446: максимальная история — 904 эфира, 97 ID; Губка Боб (401), Элвинн (68), ТСН (62). B=12453026253397466416: минимальная непустая история — 1 эфир «Утро с Интером». Ties выбора по user_id, не по качеству рекомендаций. Цели A: 12001682,12002856,12001697,2400480,12002355; B: 240081,2400480,5200303,20088,200337.

Метод	A: ранги 1→5	AP	B: ранги 1→5	AP
Popularity	2400480+ 240081 2400467 200344 2400508	0.200	2400480+ 240081+ 2400467 200344 2400508	0.400
Repeat	12001682+ 12002856+ 2400480+ 12001734 12001697+	0.760	200337+ 2400480+ 240081+ 2400467 200344	0.600
CBF-28	12001682+ 12002856+ 2400480+ 240081 12001697+	0.760	200337+ 5900275 5900256 200477 2400508	0.200
AR-20-28	2400480+ 240081 2400467 2400508 200344	0.200	2400480+ 240081+ 2400508 2400467 20088+	0.520
ALS	10002893 200338 300358 120079499 90044806	0.000	200337+ 5900256 6200371 200506 5200303+	0.280
Item cosine	2400480+ 240081 2400467 200344 2400508	0.200	2400508 20088+ 240081+ 2400480+ 2400467	0.383
Время	12001682+ 12002856+ 12001734 2400480+ 12002355+	0.710	5200303+ 200337+ 2400480+ 2400508 6700482	0.600
Program lift	12001682+ 12002856+ 2400480+ 12001697+ 12001734	0.800	200337+ 5200303+ 2400480+ 2400508 6700482	0.600
v2	12001682+ 2400480+ 12002856+ 240081 12001734	0.600	200337+ 5200303+ 2400480+ 2400508 6700482	0.600
Недавний тренд	12001682+ 12002856+ 2400480+ 240081 2400508	0.600	2400480+ 200337+ 5200303+ 2400508 6700482	0.600
v4 HGB	12001682+ 12002856+ 2400480+ 240081 12001734	0.600	2400480+ 2400508 240081+ 20088+ 200337+	0.643
v5 Rank150	12001682+ 2400480+ 12002856+ 240081 12001734	0.600	2400480+ 200337+ 200344 2400508 5200303+	0.520
v6 Rank100	12001682+ 2400480+ 12002856+ 240081 12001734	0.600	2400480+ 200337+ 200344 5200303+ 2400508	0.550

«+» — попадание в Top-5 цели; нет «+» не означает отсутствие интереса или любого просмотра. Каталог ниже даёт название и категорию для каждого ID в таблице. Metadata получены после предсказаний для объяснения; будущие содержательные поля не участвуют в обучении.

ID · название · категория	ID · название · категория
20088 · 'Завтрак с 1+1'. Информационно-развлекательная программа. · Развлечения	**5900256** · Утро с Украиной. · Инфо
200337 · Утро с Интером. · Развлечения	**5900275** · 'Утро России'. · Инфо
200338 · Готовим вместе. · Познавательное	**6200371** · ДжеДАИ. · Познавательное
200344 · 'Чистоnews'. · Развлечения	**6700482** · Секретные материалы. · Другое
200477 · 'Завтрак. Выходной'. · Развлечения	**10002893** · Т/с 'Когда мы дома'. · Сериалы
200506 · Звездный путь. · Развлечения	**12001682** · М/с 'Губка Боб Квадратные Штаны'. · Детям
240081 · Факты. · Инфо	**12001697** · М/с 'Аватар: Легенда об Аанге'. · Детям
300358 · Скетч-шоу 'На троих', 4 сезон. · Развлечения	**12001734** · М/с 'Волшебные покровители'. · Детям
2400467 · 'Викна-Новости'. · Инфо	**12002355** · М/с 'Кунг-фу панда: Удивительные легенды'. · Детям
2400480 · ТСН. · Инфо	**12002856** · М/с 'Элвиннн!!! и бурундуки'. · Детям
2400508 · Сегодня. · Инфо	**90044806** · Х/ф 'Пятый элемент'. · Фильмы
5200303 · 'Следствие вели...' с Леонидом Каневским. · Познавательное	**120079499** · М/ф 'Гадкий я 2'. · Детям

8. Выбор для платформы

Для этой офлайн-задачи выбран rank86_trees100: выше среднее историческое качество, чем у отдельных обязательных методов и v2. У A итоговый AP=0.600, у B — 0.550; Это хуже Repeat у обоих примеров (0,76 / 0,60), а у B хуже v4 HGB (0,643). У A преобладает детский контент, но есть новости. У B одного утреннего эфира мало для уверенного профиля. Эти примеры показывают индивидуальные ограничения, а не доказывают эффект для каждого зрителя.

CBF переносит общие атрибуты, AR/cosine — совместную аудиторию, Repeat — устойчивые повторные предпочтения. Временной контекст учитывает доступность эфиров и привычки, LambdaRank учится сочетать косвенные сигналы по прошлым задачам прогноза. Проверенный ALS уступил; это не доказательство непригодности всех MF. На обучающей истории A доля детских событий: 42% утром, 83% днём, 73% вечером. Это неоднородность аккаунта, не доказательство ребёнка или совместного просмотра. Новые ID не обязательно полезные открытия; отсутствие в логах не означает «никогда не смотрел». Годовая сезонность, состав домохозяйства и текущий контекст зрителя неизвестны.

Для реальной платформы требуется независимая следующая временная проверка, отдельно по типам истории и доле детских просмотров, с контролем повторов и нерелевантных новостей. Расписание покрыто ID лишь частично, горизонты 6–10 недель отличаются от тестовых 12. Никаких A/B-тестов, онлайн-эффектов или влияния на выручку не измерялось.

9. Точный файл и Kaggle

ЧЕРНОВИК: v6 ещё не отправлена / результат не подтверждён. Обязательного скриншота этой версии нет; этот PDF не готов к сдаче. Последний подтверждённый private score 0,44891 относится к другому CSV — v5. Цель 0,45 не достигнута подтверждёнными данными.

Файл: runs/v6_candidate/submission_v6.csv. 1260 строк + header, 2 столбца, ровно 5 уникальных положительных ID в исходном порядке шаблона; все ID в буквальном тестовом расписании.
SHA-256: d8a4b1243933599ffc6e00605607cc6bac36c4a32097d69bee10c617143b470a

Репозиторий: github.com/dryjins/RecSys-LLMs, каталог MidTerm. **Пока работа локальная по просьбе студента; публикация кода и точного CSV ещё требуется.** Через канал курса: ровно PDF и оригинальный AI-export. Сессия продолжается; окончательный экспорт фиксируется после работы.

Личная интерпретация студента: «Будущие эфиры помогали выбирать передачи, которые пользователь действительно сможет посмотреть в нужный период, а время просмотра - отличать устойчивый интерес от случайного переключения. Одного сходства с историей недостаточно: даже похожая передача может оказаться недоступной по расписанию, а короткий просмотр не обязательно означает интерес. Главное оставшееся ограничение - модель судит о предпочтениях по косвенным сигналам и не знает, кто именно сейчас смотрит телевизор и что ему хочется посмотреть.»

Источники и использованная помощь

[1] LLM4Rec. Midterm Quiz.pptx
Прочитаны текст и изображения слайдов 2–9: методы, MAP@5, формат и скриншот.

[2] exam_quiz_FKN.md; ../homework_guidelines.pdf
Прочитаны условия экзамена и HW, включая Gate 0, личное объяснение и оригинальную AI-сессию. Строгий формат: 5 основных страниц + источники.

[3] https://www.kaggle.com/competitions/sweettv-tv-program-recommender
Авторизованные Data / Overview / Rules / Submissions: канал, Top-5 с ≥80%, public/private по пользователям, правила приняты. Перед четвёртой попыткой форма показала 97 remaining; счётчики расходятся с обзорным лимитом 10/day.

[4] https://yifanhu.net/PUB/cf.pdf
Hu, Koren, Volinsky. Collaborative Filtering for Implicit Feedback Datasets. Прочитаны основная часть §4, формулы 3–6; собственная реализация ALS.

[5] https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html
Официальная документация estimator, параметры fit и отключение случайного early stopping.

[6] https://scikit-learn.org/stable/modules/feature_extraction.html
Официальная документация DictVectorizer / TF-IDF, формирование разреженных атрибутов.

[7] https://docs.scipy.org/doc/scipy/reference/sparse.html
Официальная документация CSR и матричных операций.

[8] https://duckdb.org/docs/2.0/data/csv/overview
Официальная документация CSV ingestion; типы ключей задаются явно.

[9] https://lightgbm.readthedocs.io/en/stable/pythonapi/lightgbm.LGBMRanker.html
Официальная документация LGBMRanker: группы запросов, параметры fit.

[10] https://lightgbm.readthedocs.io/en/stable/Parameters.html
Официальные параметры LambdaRank, label_gain, truncation и rank_xendcg.

Документация прочитана для использованных операций; сторонний рекомендательный код, дополнительные данные и готовые модели не подключались. AI-помощь и собственные рассуждения студента разделены в report/personal_verification.json. Журнал всех расширений: report/EXPERIMENT_JOURNAL.md; проверка ограничений: report/RULES_AUDIT.md. Материалы PDF генерируются из фактических JSON; отсутствие score не заменяется вымышленным числом.